AI4I PREDICTIVE MAINTENANCE

One-page project summary · Data Mining · ENSI · 2026–2027

Problème métier

Anticiper les défaillances de machines à partir de leurs conditions de fonctionnement afin d'aider à prioriser les inspections et la maintenance préventive. La cible est binaire : panne ou absence de panne. Le résultat est une estimation statistique, pas une garantie de panne.

Données et préparation

Jeu public AI4I 2020 Predictive Maintenance (UCI) : 10 000 observations et 14 colonnes dans le fichier source. La cible *Machine failure* comprend 339 pannes (3,39 %). Les prédicteurs retenus sont le type de machine, les températures de l'air et du procédé, la vitesse de rotation, le couple et l'usure de l'outil. Les identifiants UDI/Product ID et les indicateurs de modes de panne (TWF, HDF, PWF, OSF, RNF) doivent être exclus pour éviter la fuite de cible. Le pipeline prévoit imputation, standardisation numérique et encodage one-hot des variables catégorielles. Découpage expérimental stratifié : 80 % entraînement / 20 % test.

Modèles et résultats expérimentaux

L'application compare Régression logistique, arbre de décision, KNN, Random Forest et XGBoost ; l'optimisation des hyperparamètres est optionnelle. Dans une expérience antérieure consignée pour ce projet, XGBoost a été retenu comme modèle performant. Au seuil 0,75, les résultats rapportés sur le jeu de test étaient :

Accuracy	Precision	Recall	F1-score	ROC-AUC	PR-AUC
0,986	**0,823**	**0,750**	**0,785**	**0,973**	**0,826**

Application et recommandations

Streamlit fournit l'exploration, l'entraînement et la comparaison des modèles, les courbes ROC et précision-rappel, la matrice de confusion, le réglage du seuil et la prédiction individuelle. FastAPI expose la prédiction du modèle sauvegardé. En pratique, surveiller ensemble rappel (pannes manquées), précision (fausses alertes), F1 et PR-AUC ; choisir le seuil sur un jeu de validation indépendant, puis tester sur des données réelles récentes avant tout usage opérationnel.

Limites

La classe panne est rare ; l'accuracy seule ne suffit pas. Les métriques ci-dessus proviennent d'une expérience antérieure et doivent être recalculées avec la version finale soumise, les mêmes variables et un protocole documenté. Le jeu public peut ne pas représenter toutes les machines réelles. **Module 5 — Explainable AI (SHAP/LIME) est inclus dans cette version :** l'application propose des méthodes d'explicabilité globale et locale pour aider à interpréter le comportement du modèle. Ces explications décrivent les contributions estimées des variables aux prédictions ; elles ne démontrent pas de relation causale et doivent être interprétées avec prudence.

Stack : Python · Pandas · scikit-learn · XGBoost · Plotly · Streamlit · FastAPI · Uvicorn · SHAP · LIME. **Résultats à confirmer sur le code final.**